

گزارش کار جامع پروژه Neural-GPS

ذهن خوانی موش و رمزگشایی سلول های مکانی هیپوکامپ

توسعه دهنده: Ali

مخزن گیت هاب: Neural-GPS

۳ مرداد ۱۴۰۵

چکیده

این گزارش به بررسی و تحلیل عمیق پروژه Neural-GPS می پردازد؛ پروژه ای که با هدف شبیه سازی فعالیت سلول های مکانی در هیپوکامپ موش و رمزگشایی موقعیت مکانی او طراحی شده است. در این مستند، ما چرخه کامل تبدیل محرک های فیزیکی به کدهای عصبی (Encoding) و فرآیند معکوس آن (Decoding) را با استفاده از مدل های آماری پیشرفته، تئوری اطلاعات شانون، کاهش ابعاد (PCA) و استنتاج بیزی بررسی می کنیم. هدف این گزارش، ارائه یک چارچوب ریاضی دقیق و قابل فهم برای درک مکانیزم های بازنمایی فضایی در مغز پستانداران است.

فهرست مطالب

۳	۱	مقدمه و طرح مسئله
۳	۲	فاز اول: مدل‌سازی رمزگذاری عصبی با GLM
۳	۱.۲	معادله نرخ شلیک (Firing Rate)
۴	۳	فاز دوم: تحلیل اطلاعات متقابل (Mutual Information)
۴	۱.۳	آنتروپی و کاهش عدم قطعیت
۴	۴	فاز سوم: کشف منیفلد عصبی با PCA
۵	۱.۴	تحلیل مؤلفه‌های اصلی (PCA)
۵	۵	فاز چهارم: رمزگشایی بیزی (Bayesian Decoding)
۵	۱.۵	قانون بیز در رمزگشایی عصبی
۶	۶	تحلیل نتایج شبیه‌سازی (بررسی تصویر)
۶	۱.۶	تحلیل نمودارهای چهارگانه
۷	۷	نتیجه‌گیری

۱ مقدمه و طرح مسئله

هیپوکامپ (Hippocampus) یکی از ساختارهای کلیدی در مغز پستانداران است که نقش اساسی در حافظه و ناوبری فضایی ایفا می‌کند. کشف «سلول‌های مکانی» توسط جان اوکیف (که منجر به دریافت جایزه نوبل در سال ۲۰۱۴ شد)، نشان داد که مغز دارای یک سیستم موقعیت‌یاب داخلی (GPS) است.

در پروژه **Neural-GPS**، ما فرض می‌کنیم یک موش در یک مسیر خطی یک‌بعدی به طول ۱۰۰ سانتی‌متر ($x \in [0, 100]$) در حال حرکت است. همزمان، فعالیت قطار اسپایک (Spike Trains) مربوط به ۵۰ نورون از هیپوکامپ او ثبت می‌شود. چالش اصلی ما در این پروژه، فرموله‌بندی ریاضی این سیستم در دو فاز کلی است:

• **رمزگذاری (Encoding):** چگونه متغیر پیوسته مکان، به قطارهای گسسته اسپایک تبدیل می‌شود؟

• **رمزگشایی (Decoding):** چگونه می‌توان با مشاهده الگوی فعالیت این ۵۰ نورون، مکان دقیق موش را در هر لحظه تخمین زد؟

۲ فاز اول: مدل‌سازی رمزگذاری عصبی با GLM

در علوم اعصاب محاسباتی، فعالیت نورون‌ها پدیده‌ای تصادفی اما ساختاریافته است. برای شبیه‌سازی این رفتار، از مدل‌های خطی تعمیم‌یافته (GLM) استفاده می‌شود که به ما اجازه می‌دهد نویز پواسون را با وابستگی‌های غیرخطی ترکیب کنیم.

۱.۲ معادله نرخ شلیک (Firing Rate)

فرض کنید $\lambda_i(t)$ نرخ شلیک مورد انتظار نورون i در زمان t باشد. ما این نرخ را با تابع نمایی (به عنوان Link Function) به شکل زیر مدل می‌کنیم:

$$\lambda_i(t) = \exp \left(c - \frac{(x(t) - \mu_i)^2}{2\sigma^2} + h \cdot y_i(t-1) \right)$$

در این معادله، سه جزء اساسی وجود دارد:

۱. **میدان دریافت (Receptive Field):** عبارت $\frac{(x(t) - \mu_i)^2}{2\sigma^2}$ نمایانگر یک منحنی زنگوله‌ای گاوسی است. μ_i مکان مطلوب نورون (مرکز میدان دریافت) و σ عرض این میدان است. هرچه موش به μ_i نزدیک‌تر باشد، این عبارت کوچکتر شده و تابع نمایی مقدار بزرگتری تولید می‌کند.

۲. اثر تاریخچه و تحریک‌ناپذیری (Refractory Period): متغیر $y_i(t-1)$ نشان‌دهنده وقوع اسپایک در لحظه قبل است. ضریب h (که معمولاً یک عدد منفی بزرگ است) تضمین می‌کند که اگر نورون به تازگی شلیک کرده باشد، احتمال شلیک مجدد آن به شدت کاهش یابد.

۳. تولید اسپایک: تعداد اسپایک‌ها در یک بازه زمانی Δt از توزیع پواسون پیروی می‌کند:

$$P(s_i|\lambda_i) = \frac{(\lambda_i \Delta t)^{s_i} e^{-\lambda_i \Delta t}}{s_i!}$$

۳ فاز دوم: تحلیل اطلاعات متقابل (Mutual Information)

همه نورون‌ها در شبکه به یک اندازه برای تخمین مکان مفید نیستند. برای سنجش ارزش اطلاعاتی هر نورون، از تئوری اطلاعات شانون بهره می‌بریم.

۱.۳ آنتروپی و کاهش عدم قطعیت

اطلاعات متقابل بین مکان موش (X) و نرخ شلیک نورون (R_i) به صورت زیر تعریف می‌شود:

$$I(X; R_i) = \sum_{x \in X} \sum_{r \in R_i} P(x, r) \log_v \left(\frac{P(x, r)}{P(x)P(r)} \right)$$

این معادله محاسبه می‌کند که با دانستن وضعیت شلیک نورون i ، چقدر از ابهام (آنتروپی) ما در مورد مکان موش کاسته می‌شود. نورون‌هایی که دارای میدان دریافت بسیار تیز (مقدار σ کوچک) هستند، معمولاً اطلاعات متقابل بالاتری دارند، زیرا شلیک آن‌ها به معنای حضور قطعی موش در یک نقطه خاص است.

۴ فاز سوم: کشف منیفلد عصبی با PCA

فضای فعالیت ۵۰ نورون، یک فضای ۵۰ بعدی است. با این حال، از آنجا که محرک خارجی (مکان) تنها یک بُعد دارد، انتظار می‌رود که دینامیک شبکه عصبی روی یک منیفلد (Manifold) با ابعاد پایین‌تر در این فضای ۵۰ بعدی قرار گیرد.

۱.۴ تحلیل مؤلفه‌های اصلی (PCA)

با استفاده از ماتریس کوواریانس سیگنال‌های هموارشده، بردارهای ویژه (Eigenvectors) و مقادیر ویژه (Eigenvalues) محاسبه می‌شوند:

$$\Sigma \mathbf{v} = \lambda \mathbf{v}$$

با تصویر کردن داده‌ها روی دو مؤلفه اصلی اول (PC ۱ و PC ۲)، ساختار هندسی نهفته در فعالیت عصبی آشکار می‌شود که معمولاً ساختاری پیوسته و متناسب با مسیر فیزیکی دارد.

۵ فاز چهارم: رمزگشایی بیزی (Bayesian Decoding)

در این مرحله، هدف یافتن محتمل‌ترین مکان موش با داشتن بردار فعالیت عصبی $S = [s_1, \dots, s_{50}]$ در یک پنجره زمانی مشخص است.

۱.۵ قانون بیز در رمزگشایی عصبی

با استفاده از قانون بیز داریم:

$$P(X = x|S) = \frac{P(S|X = x) \cdot P(X = x)}{P(S)}$$

• **درست‌نمایی: (Likelihood)** با فرض استقلال شلیک نورون‌ها، احتمال مشاهده بردار S در صورت حضور در مکان x برابر است با حاصل ضرب توزیع‌های پواسون:

$$P(S|X = x) = \prod_{i=1}^{50} \frac{(\lambda_i(x)\Delta t)^{s_i} e^{-\lambda_i(x)\Delta t}}{s_i!}$$

• **احتمال پیشین: (Prior)** برای جلوگیری از پیش‌بینی‌های غیرمنطقی (مانند جهش ناگهانی موش از یک سر مسیر به سر دیگر)، از یک توزیع نرمال بر پایه مکان قبلی استفاده می‌کنیم:


$$P(X_t = x) \sim \mathcal{N}(x_{t-1}, \sigma_{speed}^2)$$

در نهایت، با استفاده از روش **(MAP) Posterior A Maximum**، نقطه‌ای که تابع پسین (Posterior) در آن ماکزیمم است به عنوان مکان تخمینی انتخاب می‌شود:

$$\hat{x}_{MAP} = \arg \max_x P(X = x|S)$$

۶ تحلیل نتایج شبیه‌سازی (بررسی تصویر)

در این بخش، به تحلیل دقیق خروجی‌های بصری پروژه که در تصویر ۱ آورده شده است، می‌پردازیم.



شکل ۱: نتایج جامع شبیه‌سازی ذهن‌خوانی موش در ۴ فاز. (بالا چپ: منحنی‌های تنظیم، بالا راست: اطلاعات متقابل، پایین چپ: منیفلد عصبی، PCA پایین راست: نتیجه رمزگشایی بیزی)

۱.۶ تحلیل نمودارهای چهارگانه

۱. فاز ۱ - منحنی‌های تنظیم: در نمودار بالا-چپ، مشاهده می‌کنیم که سه نورون مختلف (نورون ۴، ۱۰ و ۱۶) هر کدام در نقاط خاصی از مسیر (حدود ۲۵، ۵۵ و ۸۵ سانتی‌متر) بیشترین فعالیت را دارند. انطباق نقاط داده‌های تجربی با خطوط برازش‌شده مدل GLM نشان‌دهنده دقت بالای مدل گاوسی-پواسون در شبیه‌سازی میدان‌های دریافت است.

۲. **فاز ۲ - اطلاعات متقابل:** نمودار میله‌ای در بالا-راست، نوروها را بر اساس میزان اطلاعاتی که درباره مکان موش می‌دهند مرتب کرده است. نورو ۱۸ با بیش از ۱۰۰ بیت اطلاعات، ارزشمندترین نورو در این پنجره زمانی است. این تفاوت در ارزش اطلاعاتی، اهمیت انتخاب ویژگی در شبکه‌های BCI را نشان می‌دهد.

۳. **فاز ۳ - منیفلد عصبی:** در نمودار پایین-چپ، داده‌های ۵۰ بعدی به ۲ بُعد کاهش یافته‌اند. نقاط بر اساس مکان واقعی موش رنگ‌آمیزی شده‌اند (از بنفش برای ۰ تا زرد برای ۱۰۰ سانتی‌متر). شکل ۷ مانندی که در این فضا تشکیل شده، نشان می‌دهد که شبکه عصبی یک بازنمایی توپولوژیک بسیار منظم و پیوسته از فضای فیزیکی خطی ایجاد کرده است.

۴. **فاز ۴ - رمزگشایی بیزی:** نمودار پایین-راست، اوج موفقیت پروژه را نشان می‌دهد. منحنی مشکی حرکت سینوسی واقعی موش در زمان را نشان می‌دهد و منحنی قرمز، تخمین مدل بیزی ما صرفاً بر اساس خوانش اسپایک‌ها است. ردیابی بسیار دقیق مسیر با خطای میانگین مربعات (RMSE) برابر با ۱۶.۵ سانتی‌متر، اثبات می‌کند که استنتاج بیزی توانسته است نویز پواسون را به خوبی فیلتر کرده و مکان را با دقت بالایی ذهن‌خوانی کند.

۷ نتیجه‌گیری

پروژه **Neural-GPS** با موفقیت نشان داد که چگونه می‌توان با استفاده از ابزارهای قدرتمند آمار و یادگیری ماشین، به درک عمیقی از کدهای عصبی دست یافت. ترکیب مدل GLM برای تولید داده‌های واقع‌گرایانه، تئوری اطلاعات برای سنجش اهمیت، PCA برای کشف ساختارهای پنهان و استنتاج بیزی برای تخمین حالت، یک خط لوله (Pipeline) کامل برای پردازش سیگنال‌های مغزی ارائه می‌دهد که قابلیت تعمیم به محیط‌های دوبعدی و سه‌بعدی پیچیده‌تر را نیز داراست.